Cahier des charges

ISSE-05 • Suivi de flotte de véhicules • 6 novembre 2026

Équipe : quatre noms à compléter. Document à personnaliser après validation locale.

1. Contexte et objectif

Le sujet ISSE-05 du PDF Projets_BigData_ADIA_IL_ISSE.pdf demande de suivre une flotte de véhicules, d'analyser la conduite et de détecter les excès de vitesse et sorties de zone. Le projet utilise des boîtiers GPS simulés, autorisés comme source dans le sujet.

Périmètre : douze véhicules évoluant autour de Casablanca. La simulation n'est pas un trafic routier réel et les seuils sont des règles pédagogiques.

2. Exigences fonctionnelles

Collecter un flux GPS via MQTT et Kafka ; historiser les messages bruts ; contrôler la qualité ; gérer les doublons et mises à jour dans Hudi ; afficher la dernière position ; calculer distance et vitesse quotidiennes ; lister les incidents ; identifier des zones d'arrêt par KMeans ; produire un rapport de conduite quotidien.

3. Architecture et contraintes

GPS Python → Mosquitto → pont Python → Kafka positions → Spark Structured Streaming → MinIO Bronze et Hudi Silver → Spark SQL/MLlib → Hudi Gold → exports JSON → Streamlit. Airflow orchestre le calcul Gold et le rapport. Un seul fichier docker-compose.yml décrit la plateforme.

Versions : Spark 3.5.3, Hudi 0.15.0 pour Spark 3.5 et Scala 2.12, Kafka 3.8.0, Airflow 2.10.4. Le démonstrateur est local, avec accès aux interfaces depuis localhost.

4. Données et règles

Chaque message contient event_id, vehicle_id, event_ms, latitude, longitude et speed_kmh. Horodatage UTC en millisecondes. Excès au-dessus de 80 km/h. Zone : latitude [33.50, 33.66], longitude [-7.72, -7.48]. Arrêt : vitesse inférieure ou égale à 5 km/h.

Validation : coordonnées terrestres, vitesse entre 0 et 220, identifiants renseignés et horodatage positif. Rejets isolés. event_id sert de clé de dédoublonnage. La distance est calculée entre points consécutifs ; les trous supérieurs à cinq minutes sont exclus.

5. Organisation du groupe

Quatre étudiants de la même filière sont obligatoires. Répartition proposée : ingestion ; stockage/Hudi ; Spark/MLlib ; Airflow/dashboard. Docker et l'intégration sont collectifs. Les noms et comptes doivent être complétés dans EQUIPE.md. Chacun réalise des contributions réelles avec son propre compte Git.

6. Livrables et critères de recette

Livrables : ce cahier des charges PDF ; dépôt Git avec Compose, producteurs, jobs Spark, DAG et README ; rapport PDF ; présentation PDF et PPTX.

Recette : lancement Compose ; JSON visibles dans positions ; Bronze alimentée ; Silver et Gold lisibles avec métadonnées Hudi ; absence de doublons event_id ; alertes cohérentes ; DAG réussis ; carte et export CSV ; modèle KMeans sauvegardé ; reprise après redémarrage sans suppression des volumes.

7. Jalons et limites

Jalons proposés : cadrage ; ingestion ; stockage ; traitements ; orchestration ; intégration ; recette ; soutenance. Aucune date de remise n'est inventée : le PDF situe la soutenance à la dernière séance de TP.

La validation complète Docker reste à réaliser sur le PC. Ressources recommandées : 16 Go de RAM machine, 8 Go pour Docker et 25 Go libres. La plateforme n'est pas dimensionnée ni sécurisée pour un déploiement de production.